Kev-4B 前后对照评测：原版与 POL2 score-v2 M10

PoL-Governance · Session B 独立评测 · 2026-10-28 · 单文件自包含报告

微调后的模型在准确率上略有提升，但在概率校准、风险控制和自动处置能力上明显变差；第三方一致性基准上的分数上升，但那一指标不是准确率，也不能作为能力提升的证据。

数据集　模型与训练　主结果　校准与风险　稳健性　外部对标　经验与失败　复现

评测数据集：只用了私有保留集

本文所有主结果只使用一份事先冻结的**私有保留集**（模型训练和选型时都看不到它）。它包含 **6,541 个情境条目**和 **7,990 道封闭式问题**；问题分为三类：choice（从候选中选一个）5,501 道、noul（是/否）1,446 道、score（按等级打分）1,043 道。全部为英文。

评测时每道题独立计分。由于模型只在有限长度的输入上有已验证能力，最终进入比较的是 **7,347 道题**（来自 6,299 个条目）——这是本文所有表格和图表的分母；其余题目不属于共同可评测范围，不参与任何数字。被评测子集的三类题为 choice 5,194 / noul 1,221 / score 932。

两个领域：决策机制（decision_mechanics）2,386 个条目、知识推理（knowledge_reasoning）4,155 个条目。输入文本长度（字符）中位数 312，90 分位 643，最长 13,972；按 token 计，已评测题目的状态长度中位数 74、90 分位 165、最大 383。选项数从 2 到 68 不等。

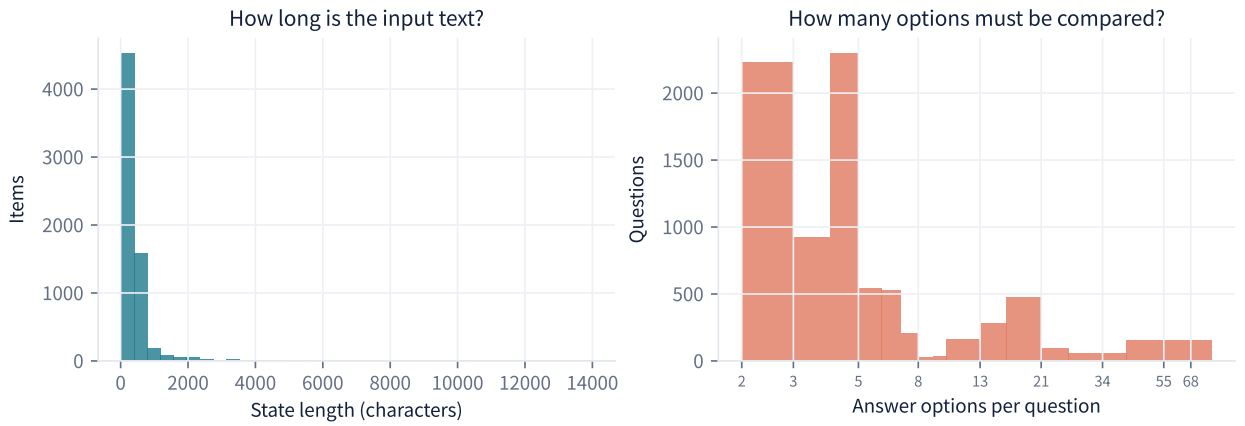


图 1　数据集形态：左为输入文本长度（字符），右为每题的候选选项数（对数横轴）。

> 读法：输入多为几百字符的短文本，少数长文档；选项数大部分在 2–8 之间，但也有少量几十个选项的题目——后一类对准确率影响很大，后文会按选项数分层。

数据边界：私有保留集只在本机隔离环境使用，只导出聚合数字，评测后删除临时副本；已核对它与微调模型训练数据的重叠：**重叠为零**。

模型与训练配置

被测模型是 **Kev**：把决策问题当作"在候选选项之间做指针选择"的小模型族，底座 Qwen3.5-4B-Base；公开代码固定在 commit `2074cc44`。比较同一架构的两个权重：

- **原版 Kev-4B**：`jaredpalmer/kev-4b@v1.0`，Hub commit `6cfce5c2`，随权重发布的温度为 2.41（Kev 作者在自家开发集上拟合）。
- **微调版（M10）**：协作者用 POL2 score-v2 数据在原版上继续训练得到的 LoRA + pointer head，GitHub Release `pol2-score-v2-v1.0.0`。本文报告三个随机种子：**seed-43（主）**、seed-17、seed-29。三个 seed 都记录温度 1.0（未拟合）。

披露一个选择问题：seed-43 是在看到三个 seed 的既有结果之后才被选为"默认推荐版本"的。因此它的数字属于**事后选择（post-selection）**的探索性结果，不是事先预注册的确认性证据；seed-17/29 的全部结果同样列出，三个 seed 不是集成（ensemble）。

训练配置（协作者提供，本报告未重新训练）

项	值
底座	Qwen3.5-4B-Base，revision `1001bb4d`
适配方法	LoRA（r=16，α=32）+ pointer head（hidden 256）
训练数据	6,827 条：POL2 score-v2 专家规则数据 6,166 + MRI 通用决策回放 661（MIT）
超参数	1 epoch；bf16 backbone / fp32 head；batch 1，gradient accumulation 4；lr 2e-5；max_state 4096
硬件	NVIDIA GB10（≤2.5 h/seed，training only）
评测时精度	bf16（本机 RX 7900 XT / ROCm；官方评测用 fp32，见限制）

原版权重与微调权重的底座 revision 已经固定为同一 commit；微调权重的 `head.pt` 原本没有记录底座 revision，我们在隔离副本里把它固定后运行，并断言模型张量不变（详见复现节）。

主决策结果

下表是最终结果。所有数字都在同一批 7,347 道题上、用同一转换和同一环境配置计算，按“条目/情境簇”聚类做统计（见下方统计说明）。

MODEL	QUESTIONS	ACCURACY	95% CI (ACCURACY)	BRIER	NLL	ECE-10	AUTOMATION @5%	AURC
Kev-4B original	7,347	64.14%	[62.98, 65.27]	0.4773	0.9945	0.0247	18.0%	0.1694
M10 seed-43	7,347	65.09%	[64.04, 66.15]	0.5500	1.6971	0.2081	14.2%	0.1743
M10 seed-17	7,347	64.73%	[63.67, 65.83]	0.5500	1.6572	0.2153	17.2%	0.1699
M10 seed-29	7,347	64.11%	[63.03, 65.21]	0.5558	1.6465	0.2115	14.6%	0.1762

附表注：ACC（accuracy，准确率）= 答对题数 / 总题数；Brier = $(1/N)\,\Sigma_i\,\Sigma_k(p_{ik} - y_{ik})^2$（y 为 one-hot 金标，0 最好）；NLL = $-(1/N)\,\Sigma_i \log p_{i,y_i}$（正确答案概率的负对数，0 最好，对自信答错惩罚最重）；ECE-10 = 把置信度分 10 个等宽箱后，按题数加权的 |实际正确率 − 平均置信度|；automation @5% = 按置信度从高到低接收、在接收集错误率 ≤5% 时能接收的最大题目比例；AURC = 风险-覆盖曲线下面积（越低越好）。CI = 95% 置信区间（单模型区间按条目簇 bootstrap；分层图为 Wilson），n = 题目数。

指标怎么读（先看这一小节，后文的表都按它解释）

指标	公式（N 题）	含义与读法
ACC	答对题数 / N	最直观的"选对率"；越高越好，但不告诉你概率是否可信
Brier	$(1/N)\,\Sigma_i\,\Sigma_k(p_{ik} - y_{ik})^2$	整条概率分布的平方误差；0 最好。对"把错误选项也分到不少概率"的情况敏感
NLL	$-(1/N)\,\Sigma_i \log p_{i,y_i}$	正确答案概率的负对数均值；0 最好。对"很自信地答错"惩罚极大
ECE-10 / ECE-15	$\Sigma_b\,(n_b/N)\cdot\lvert acc_b - conf_b\rvert$	把置信度分成 10 或 15 个等宽箱，比较箱内平均置信度与实际正确率；0 表示完全校准。本报告并列两种分箱
automation @5%	$\text{argmax}_c\ c / N$ 使接收集错误率 ≤5%	在最多容忍 5% 错误时，能自动放行多少比例的题；越高越好，但必须同时看接收题数 n 与接收集错误率
AURC	$\int$ risk d(coverage)	按置信度排序后的风险-覆盖曲线面积；越低越好，衡量"用置信度做取舍"的整体质量
95% CI	Wilson / 配对 cluster bootstrap 95% 区间	重复抽样下该数字的波动范围；两模型比较用"配对差值"的区间，比各自区间是否重叠更准确

> **怎么读这张表：**先看 accuracy（准确率）和它的 CI——两个模型的 CI 有重叠，但配对比较（同一道题上逐题比较，见下表）更敏感。然后看后四列：它们衡量的是"概率能不能信"。准确率相近时，Brier/NLL/ECE 更小的模型在实际部署中更可靠，因为它的置信度可以用来决定哪些题自动放行、哪些交人复核。

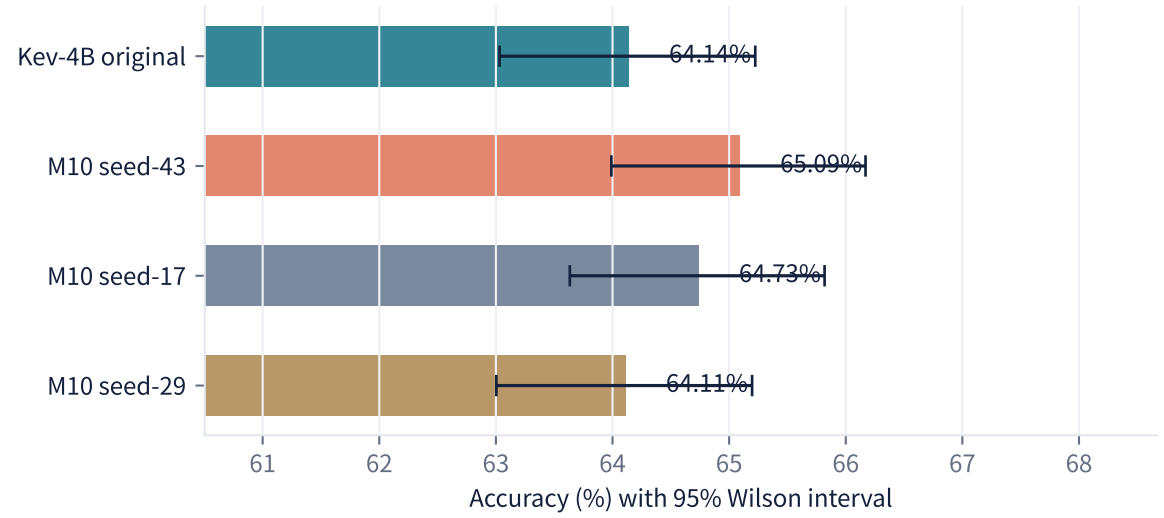


图 2　四个权重的准确率与 95% Wilson 置信区间（n=7,347）。

> 读法：条形是点估计，黑线是区间。原版与 seed-43 的区间有重叠，说明单看准确率无法区分；后文用配对检验提高灵敏度。

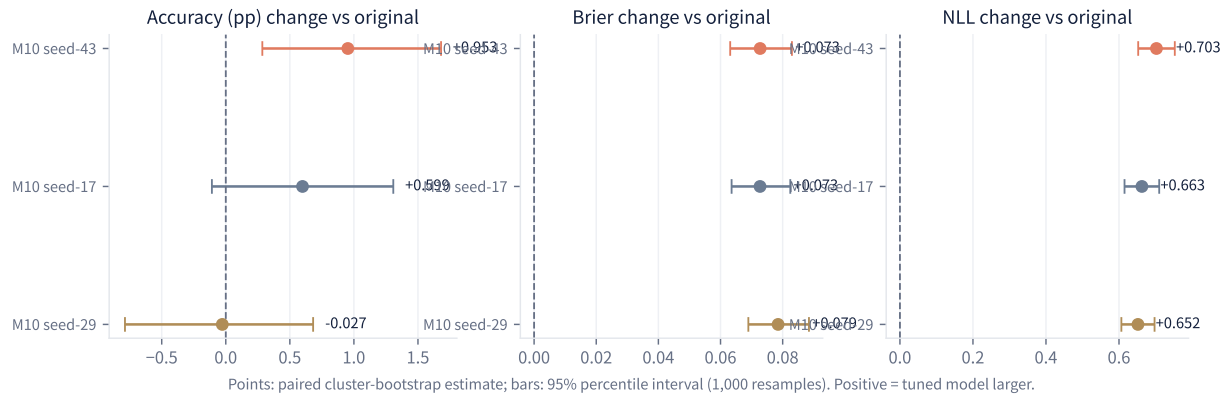


图 3　三个 seed 相对原版的变化（准确率、Brier、NLL），配对 cluster bootstrap 95% 区间。

> 读法：横轴 0 = 与原版相同；点在 0 右侧表示数值更大。准确率右侧为好，Brier/NLL 右侧为差。seed-43 的准确率区间整体在 0 右侧，Brier/NLL 区间也整体在 0 右侧——即"更准一点，但概率明显更差"。

配对统计：差异是不是真的？

同一道题被两个模型各答一次，因此正确/错误是可配对的。我们做三件事：①用**配对 cluster bootstrap**（按条目/集团簇重抽样 2,000 次）估计差值的 95% 区间；②对准确率用**McNemar 精确检验**（只比较两个模型答案不一致的题）；③对 Brier/NLL 用**簇符号翻转置换**

检验（2,000 次）得到 p 值，并用 Holm 方法控制三个 seed 的多重比较。下表同时给出效应量与检验结果。

COMPARISON	ACCURACY CHANGE	BRIER CHANGE	NLL CHANGE	MCNEMAR P	HOLM P (ACC)	PERMUTATION P (BRIER)
M10 seed-43 vs original	+1.0 pp [0.3, 1.7]	+0.0728 [+0.063, +0.083]	+0.7026 [+0.653, +0.753]	9.97e-03	2.99e-02	0.0005
M10 seed-17 vs original	+0.6 pp [-0.1, 1.3]	+0.0727 [+0.064, +0.082]	+0.6627 [+0.615, +0.710]	1.11e-01	2.22e-01	0.0005
M10 seed-29 vs original	-0.0 pp [-0.8, 0.7]	+0.0785 [+0.069, +0.088]	+0.6519 [+0.606, +0.697]	9.71e-01	9.71e-01	0.0005

> **怎么读：**“McNemar p”回答“准确率差异是否可能是巧合”，p 越小越不像巧合；“Holm p”是对三个 seed 同时比较后的校正值。Brier/NLL 的置换 p 同理。注意：统计显著不等于实际重要——seed-43 准确率只高 0.95 个百分点，但 Brier 高 0.073、NLL 高 0.70，后者的实际影响远大于前者。

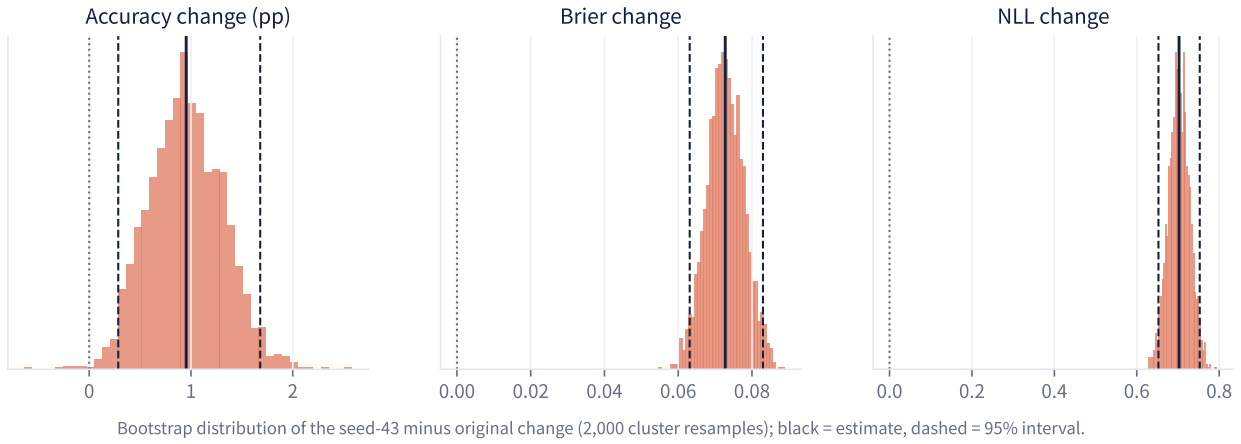


图 4　seed-43 相对原版的配对 bootstrap 分布（准确率、Brier、NLL）。

> 读法：灰色柱是 2,000 次重抽样得到的差值分布；黑色实线是点估计，虚线是 95% 区间。分布整体不跨 0（准确率在右、Brier/NLL 在左）说明差异稳定；但三者尺度不同，要看相对大小而非绝对高度。

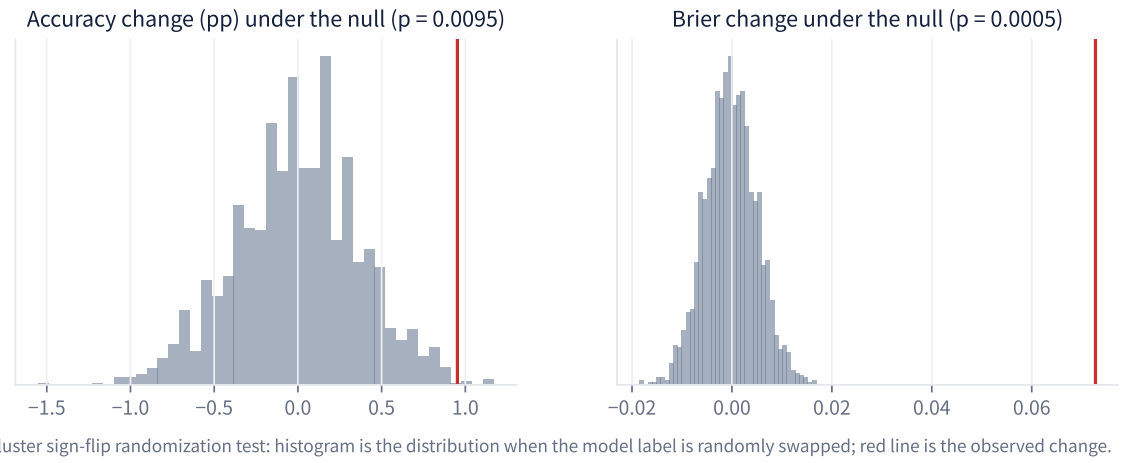


图 5　置换检验：如果两个模型其实一样好，差值会落在灰色分布里；红线是实际观测值。

> 读法：红线落在灰色分布的极端尾部（p<0.01），说明观察到的准确率与 Brier 差异不太可能只是抽样巧合。置换只检验"是否有差异"，不说明差异有多大——效应量看前面的表和森林图。

按题型、领域与选项数分层

"分层"指把同一批题按属性切开分别统计，检查提升/退化是否集中在某类题上。我们按四种方式分：题型（choice/noul/score）、领域（决策机制/知识推理）、选项数（2 / 3–4 / 5–8 / 9–26 / >26）、输入长度（字符数分桶）。下表为题型分层（其他分层见图中）。

题型	KEV-4B ORIGINAL ACC	N	M10 SEED-43 ACC	N	M10 SEED-17 ACC	N	M10 SEED-29 ACC	N
choice	62.6%	5,194	65.8%	5,194	65.7%	5,194	65.7%	5,194
noul	77.1%	1,221	71.7%	1,221	73.0%	1,221	69.6%	1,221
score	55.8%	932	52.3%	932	48.8%	932	47.9%	932

> **怎么读：**微调后 choice 题准确率上升（62.6%→65.8%），但 noul（是/否）从 77.1% 降到 71.7%、score（打分）从 55.8% 降到 52.3%。也就是说准确率的总体小升不是"全面变强"，而是能力结构改变：微调更擅长挑选项，更不擅长二元判断和等级判断。这一点与校准退化一致——训练目标更偏向"选中率"而不是"概率诚实"。

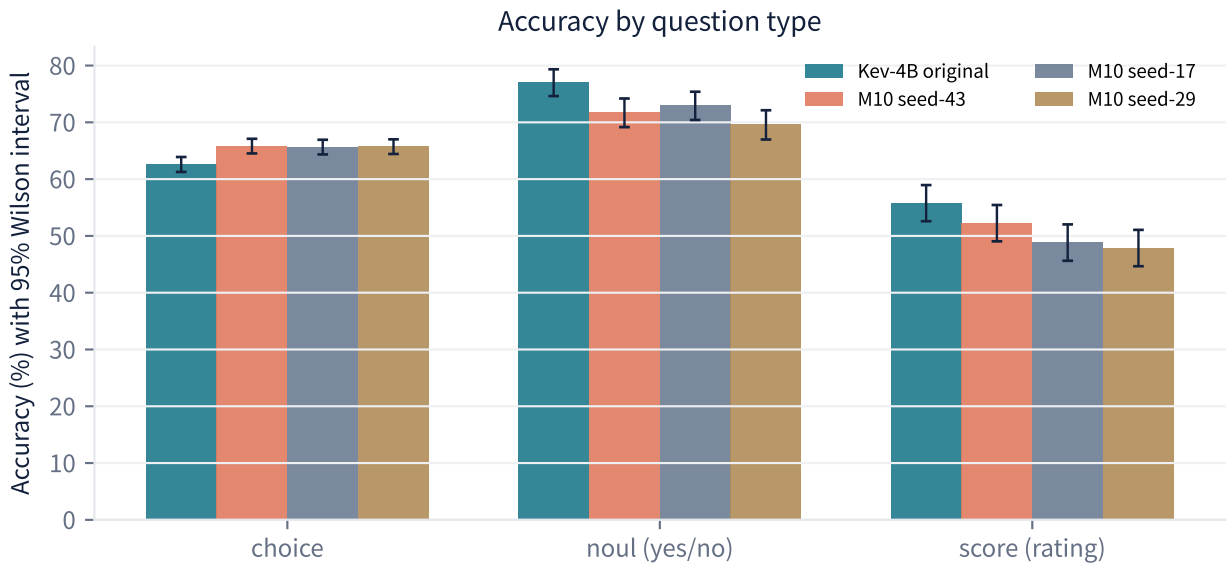


图 6　按题型分层的准确率（95% Wilson CI）。

> 读法：每组四根柱是四个权重。看组内高度差即可：choice 组微调更高，noul 与 score 组原版更高。

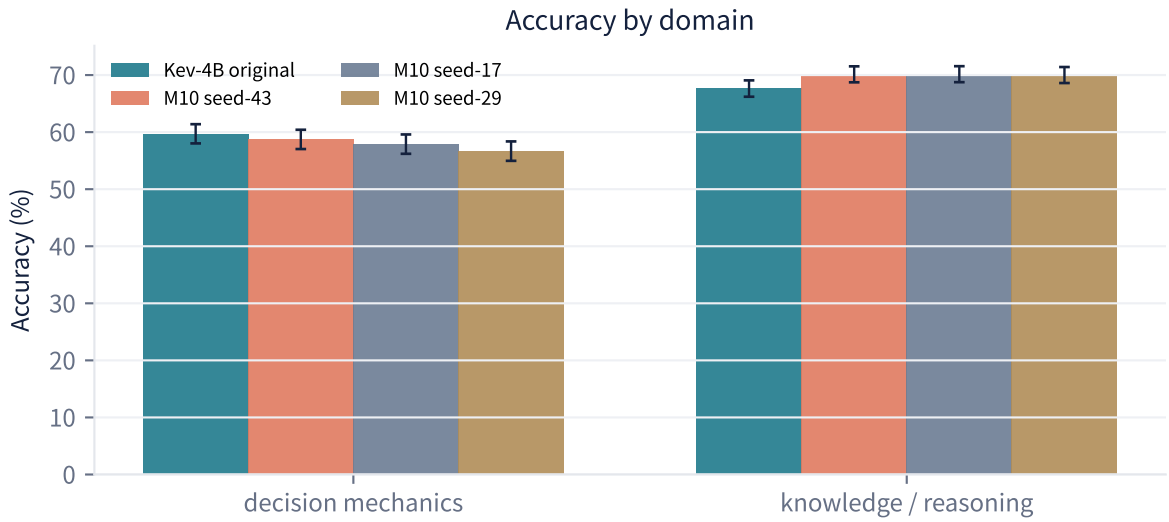


图 7　按领域分层的准确率。

> 读法：微调提升了知识推理题，但降低了决策机制题；两类题在总准确率里权重不同，因此总差异被稀释。

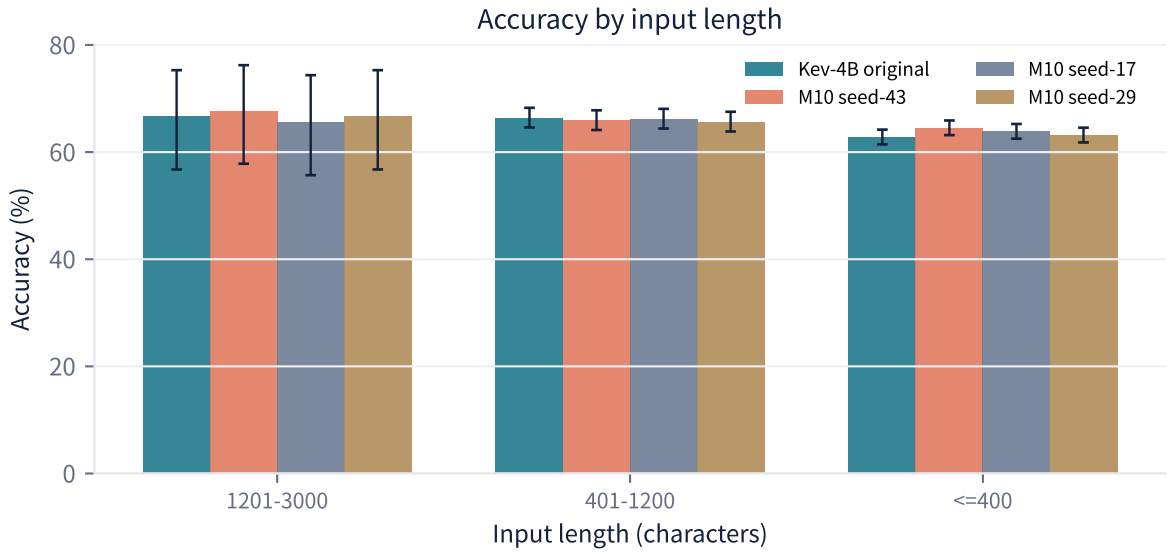


图 8　按输入长度分层的准确率（95% CI）。

> 读法：输入越长的题整体越难；原版与微调在最长一档上都明显下降，差异不集中在长文本上。

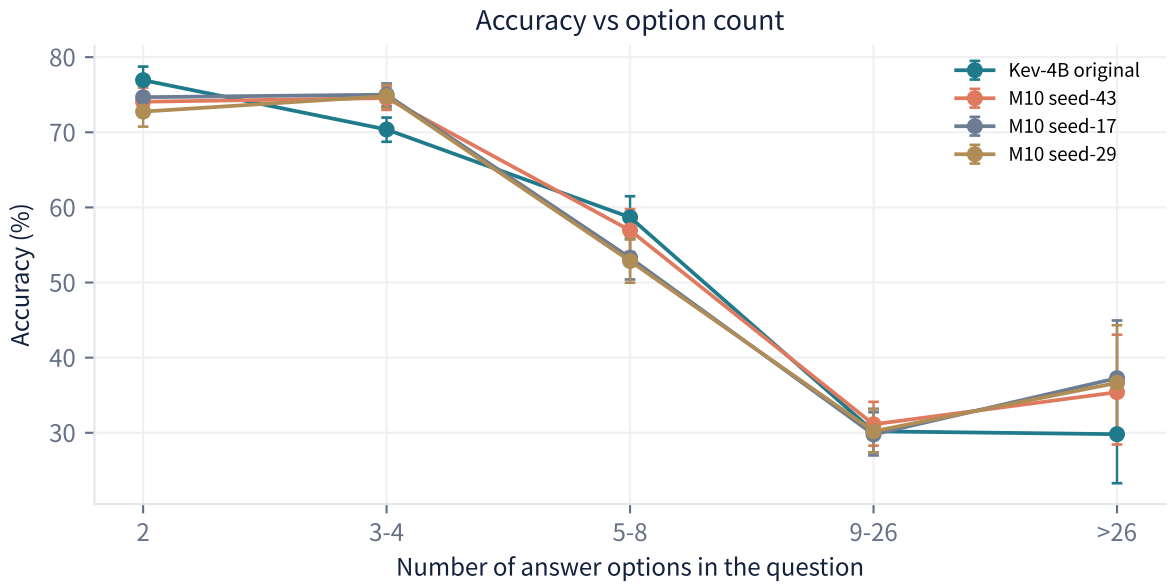


图 9　准确率随选项数变化（对数式分桶，95% CI）。

> 读法：选项越多，所有模型都越难；微调在 3–4 选项题上有优势，在 5–8 与 9–26 选项题上反而略差。

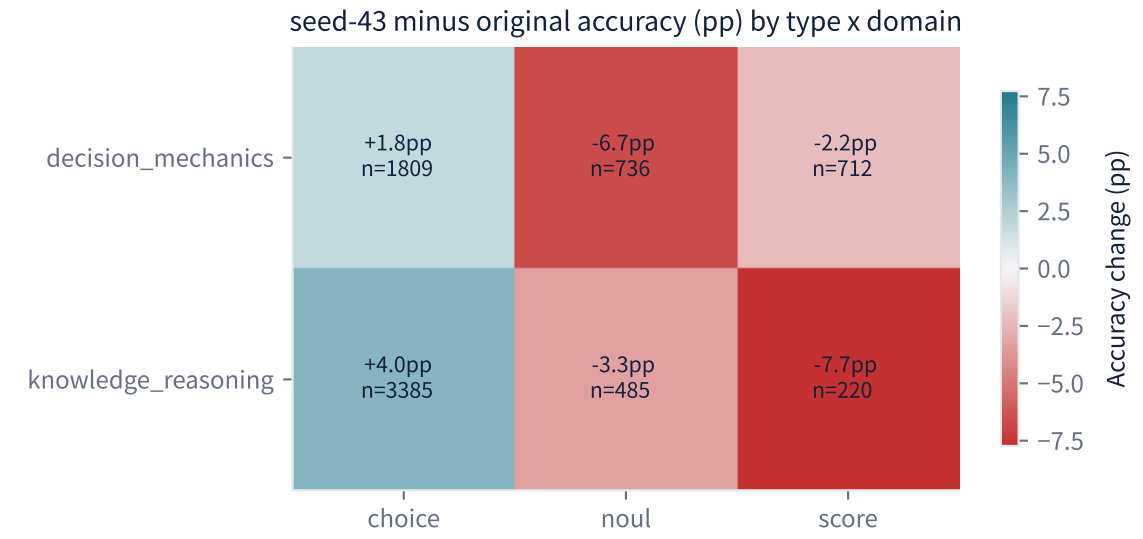


图 10　seed-43 相对原版的准确率变化（百分点），按"题型 × 领域"切分。

读法：蓝色为正、红色为负。提升集中在 choice×知识推理；noul 与 score 在两类领域都变差。颜色只表示方向，样本较少的格子（括号内 n）不要过度解读。

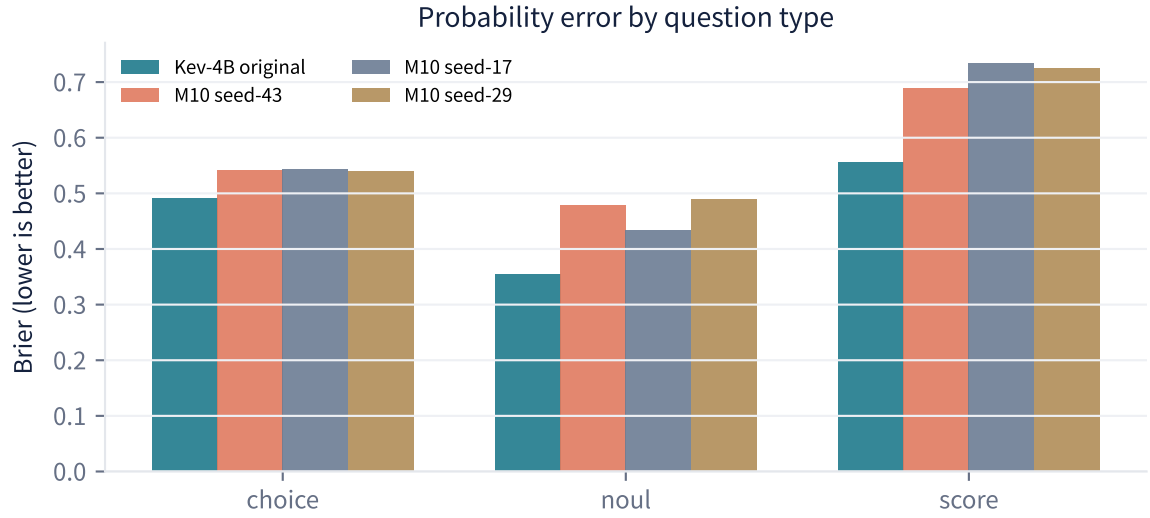


图 11　按题型的概率误差（Brier，越低越好）。

读法：四根柱一组。choice 题原版与微调差距不大，noul 与 score 题微调版明显更高——这与前面的准确率分层一致：微调在这两类题上不仅更不准，概率也更差。

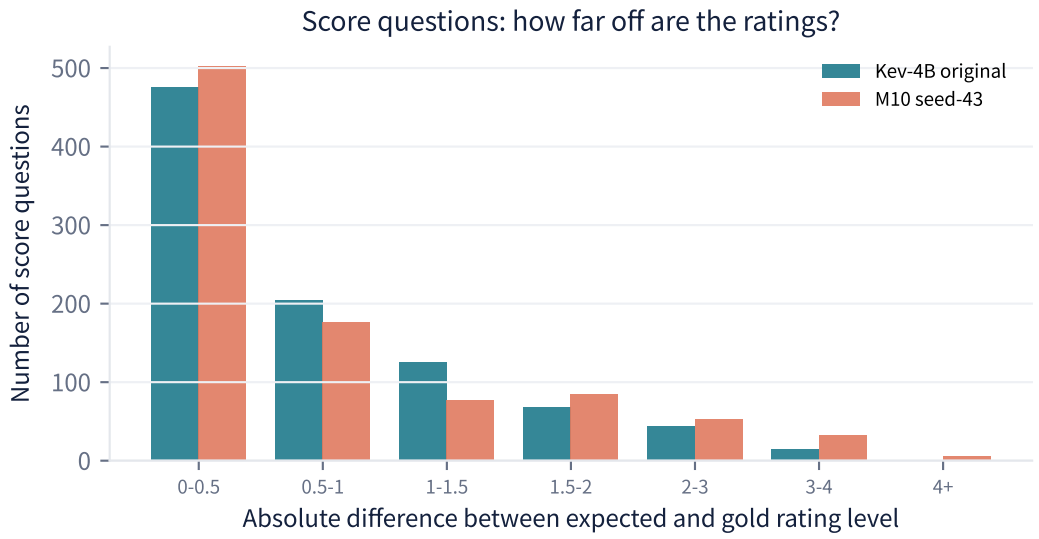


图 12　打分题的绝对等级误差分布。

> 读法：横轴是"预测期望等级与金标等级之差"，越靠左越好。微调版在 1 级以上误差的比例更高。

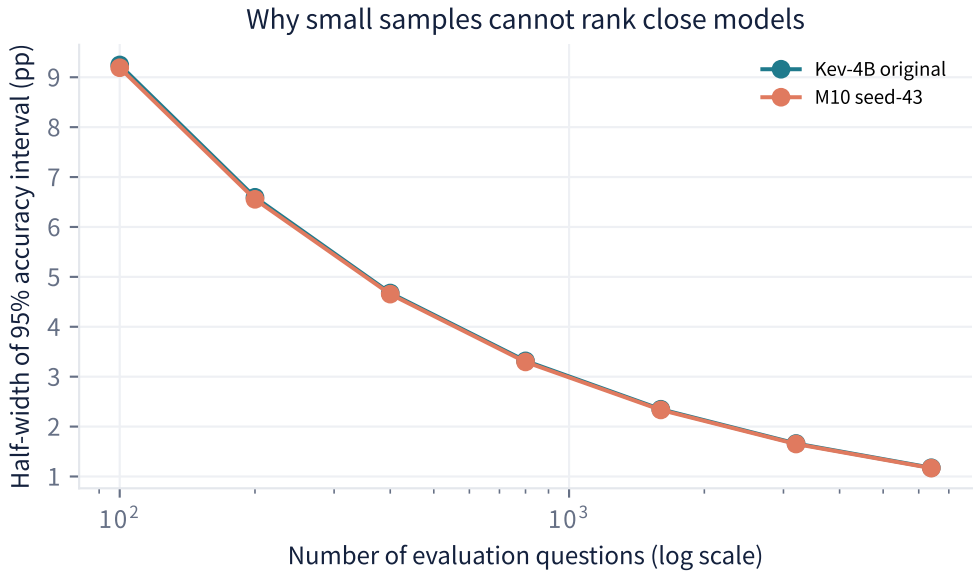


图 13　准确率置信区间半宽随题目数变化。

> 读法：本题库有 7,347 道题，95% 区间半宽约 ±1.2 个百分点；若只有 200 道题，半宽会超过 ±7 个百分点——这就是小样本无法给相近模型排名的原因。

校准与自动处置风险

决策模型不只要答对，还要**知道自己有多确定**。如果模型说“95% 确定”时实际只有 60% 正确，那么按置信度自动放行就会出错。这一节专门评估“概率是否可信”，以及它对自动处置的影响。这是本报告与只报准确率的评测最重要的区别。

指标	怎么算	怎么读
Brier	把每个选项的概率与“正确答案为 1、其余为 0”的目标做平方差后求和，再对题目取平均	综合衡量概率误差；越低越好。它对罕见类别的错误惩罚较重
NLL	正确答案所获概率的负对数，再取平均	对“自信地答错”惩罚极大；越低越好
ECE-10 / ECE-15	把置信度分 10 / 15 个等宽箱，比较每箱“平均置信度”与“实际正确率”，按箱内题数加权	0 为完全校准；0.02 可视为很校准，0.2 表示置信度严重偏离实际正确率。两套分箱结果并列，避免一种分箱的偶然性
automation @5%	按置信度从高到低接收题目，在“接收集错误率 ≤5%”约束下，最多能自动处置的题目比例	越高越好，但这是本样本上的经验值，不是真实部署的错误保证；同时要报接收题数与接收集错误率
AURC	风险-覆盖曲线（横轴覆盖率、纵轴错误率）下方面积	越低越好，衡量“用置信度排序”的整体质量

下表汇总四个权重在“概率可信度”和“自动处置”上的表现；每一列的计算方式见上一张表。

MODEL	MEAN CONFIDENCE	CONFIDENT-ERROR RATE	ECE-15	BRIER	AUTOMATION COVERAGE @5%	ACCEPTED QUESTIONS	ERROR RATE ON ACCEPTED
Kev-4B original	62.9%	0.69%	0.0227	0.4773	18.0%	1326	4.98%
M10 seed-43	85.9%	13.71%	0.2094	0.5500	14.2%	1046	4.97%
M10 seed-17	86.2%	13.38%	0.2168	0.5500	17.2%	1267	4.97%
M10 seed-	85.2%	13.41%	0.2116	0.5558	14.6%	1073	4.94%

MODEL	MEAN CONFIDENCE	CONFIDENT-ERROR RATE	ECE-15	BRIER	AUTOMATION COVERAGE @5%	ACCEPTED QUESTIONS	ERROR RATE ON ACCEPTED
29							

confident-error rate = 置信度 ≥0.9 且答错的题占全部题的比例；automation 的接收题数与接收集错误率见同表后两列。

> **怎么读：**原版模型"平均置信度 62.9% / 实际准确率 64.1%"，几乎贴住对角线；微调后的三个 seed "平均置信度 85–86% / 实际准确率 64–65%"，系统性过度自信。后果很直接：在允许 5% 错误的前提下，原版能自动处置 18.0% 的题目（接收 1,326 题、错误率 4.98%），seed-43 只能自动处置 14.2%（接收 1,046 题、错误率 4.97%）；高置信度错误（≥0.9）比例从 0.7% 升到 13.7%。

温度不是全部解释。原版权重自带一个在 Kev 开发集上拟合的温度（2.41），微调权重记录的是 1.0（未拟合）。为公平起见，我们又用两模型记录的 logits 把两者都还原到 T=1（无温度缩放），再比较一次：seed-43 的 Brier 仍高 0.026、NLL 仍高 0.37，说明差距不仅来自"没有拟合温度"，也来自微调后的概率尺度本身。按评测协议，我们没有在保留集上重新拟合温度（那会用测试数据调参）。

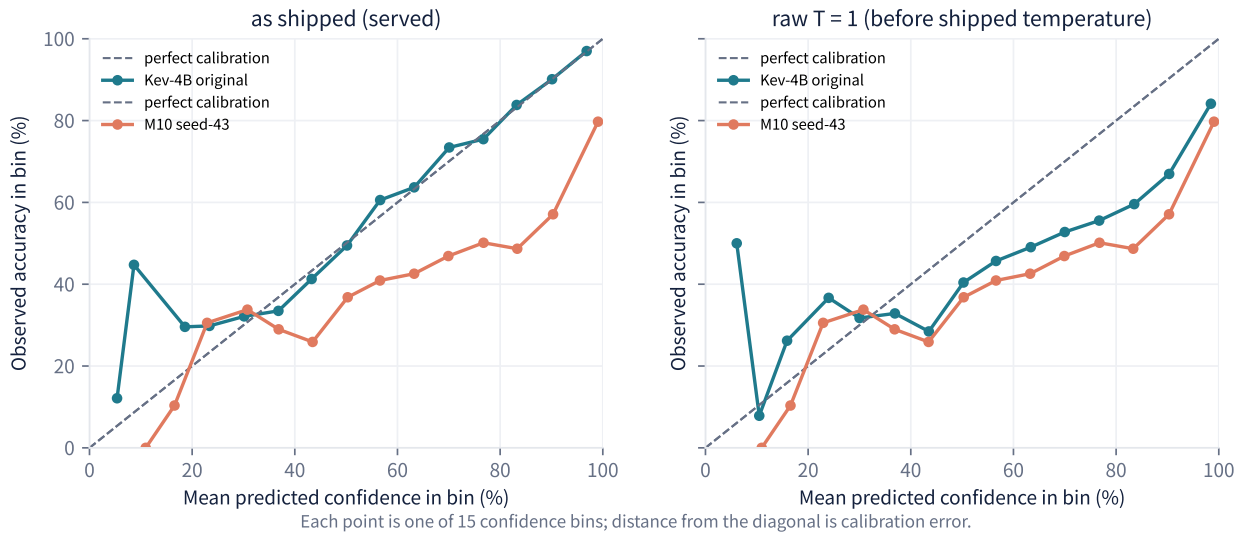


图 14　可靠性图：横轴为预测置信度，纵轴为实际正确率；虚线为完美校准。

> 读法：曲线越贴近对角线越校准。左图是"随权重交付"的配置（原版温度 2.41、微调 1.0）；右图是两者都还原到 T=1 后的结果。两图中微调版本的点都明显高于对角线——过度自信。

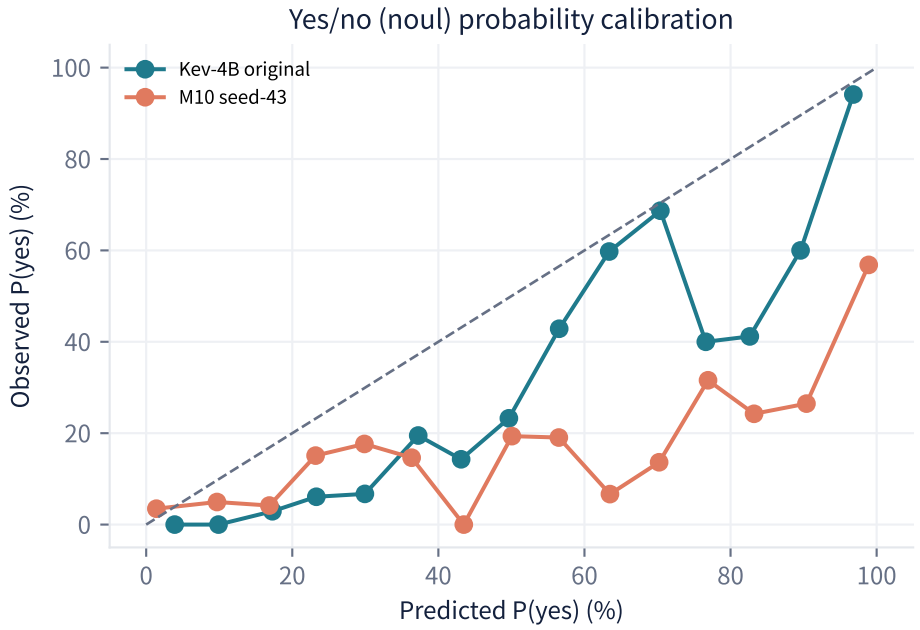


图 15　是/否题的二元校准：预测"是"的概率 vs 实际"是"的比例。

读法：同样的过度自信模式；这也是 noul 准确率下降与 Brier 变差的主要来源。

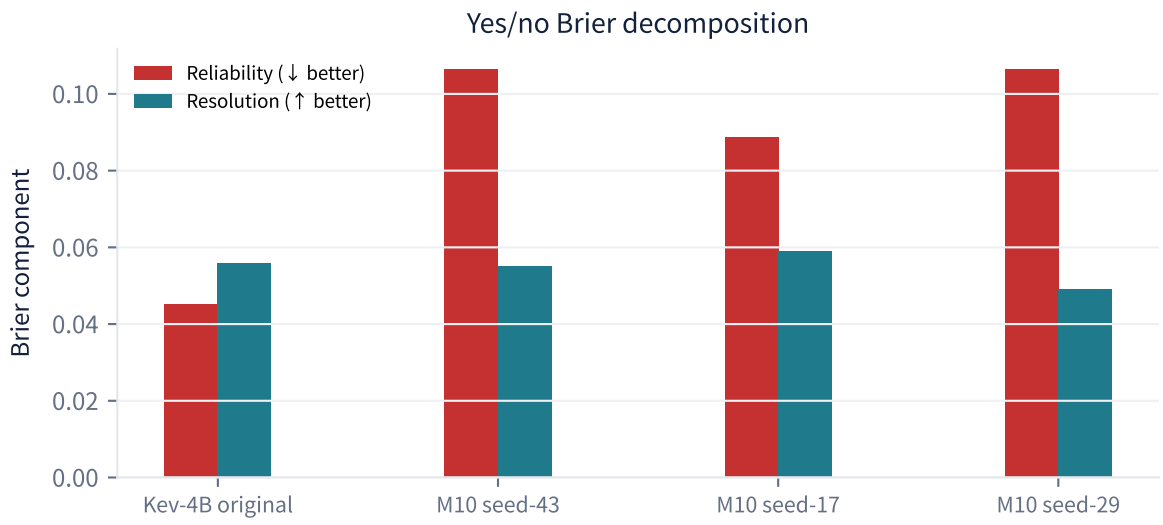


图 16　Brier 分解（是/否题）：reliability（校准误差，越低越好）与 resolution（区分能力，越高越好）。

读法：原版的校准误差小、区分能力也较好；微调版校准误差明显变大。

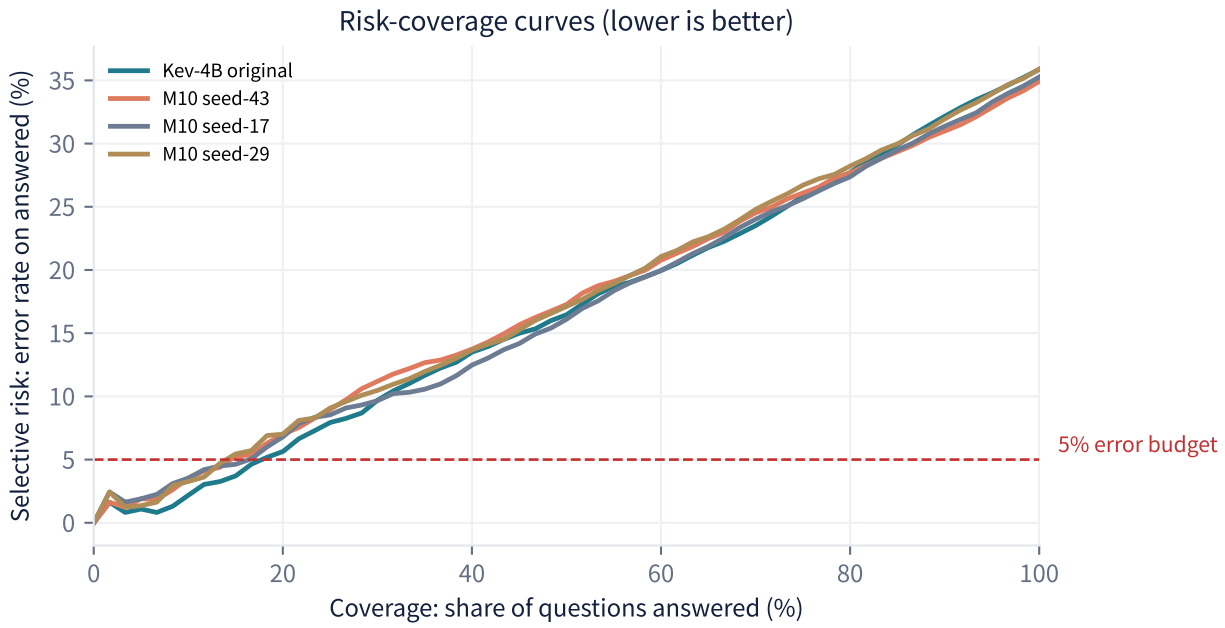


图 17　风险-覆盖曲线：覆盖率越高，错误率越高；红色虚线为 5% 错误预算。

> 读法：曲线越低越好。原版在大部分覆盖区间上错误率都低于微调版，因此能"安全地多放行一些"题目。

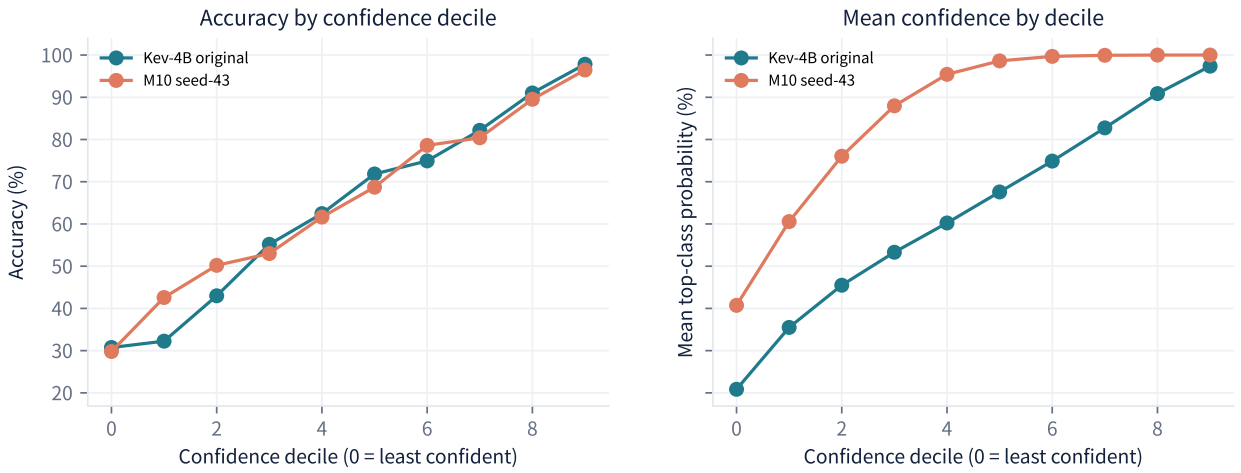


图 18　按置信度十分位看准确率与平均置信度。

> 读法：左图两条线越接近说明模型越会"按置信度排序"；右图微调版整条线更高（更自信），但准确率没有相应提高。

稳健性检查（辅助结论）

我们把同一道题换一种问法再问一次，检查答案是否稳定，共两类：**选项顺序打乱**（600 道 choice 题，顺序随机重排）与**拆题单独提问**（把一次请求里的多道题拆成独立请求）。这些检查不直接等于"是否降智"，但能说明模型对无关变化的敏感程度；结论只作辅助。

选项顺序打乱（n=600）：Kev-4B original：6.1% 平均最大概率变化、10.2% 翻转率；M10 seed-43：10.3% 平均最大概率变化、11.3% 翻转率；M10 seed-17：10.0% 平均最大概率变化、11.2% 翻转率；M10 seed-29：9.3% 平均最大概率变化、10.7% 翻转率。 **拆题单独提问**（n=1916）：Kev-4B original：0.2% 平均最大概率变化、0.2% 翻转率；M10 seed-43：0.3% 平均最大概率变化、0.5% 翻转率；M10 seed-17：0.3% 平均最大概率变化、0.3% 翻转率；M10 seed-29：0.3% 平均最大概率变化、0.4% 翻转率。

读法：选项顺序打乱时，微调三个 seed 的平均概率变化（约 9–10 个百分点）高于原版（6.1 个百分点），答案翻转率也从 10.2% 升到 10.7–11.3%；拆题单独提问的影响对所有模型都很小（平均变化 ≤0.35 个百分点）。也就是说，微调让模型对"选项怎么排"更敏感，而对"一次问几道题"不敏感——这与"更依赖表面选项模式"的解释一致，但不构成能力结论。

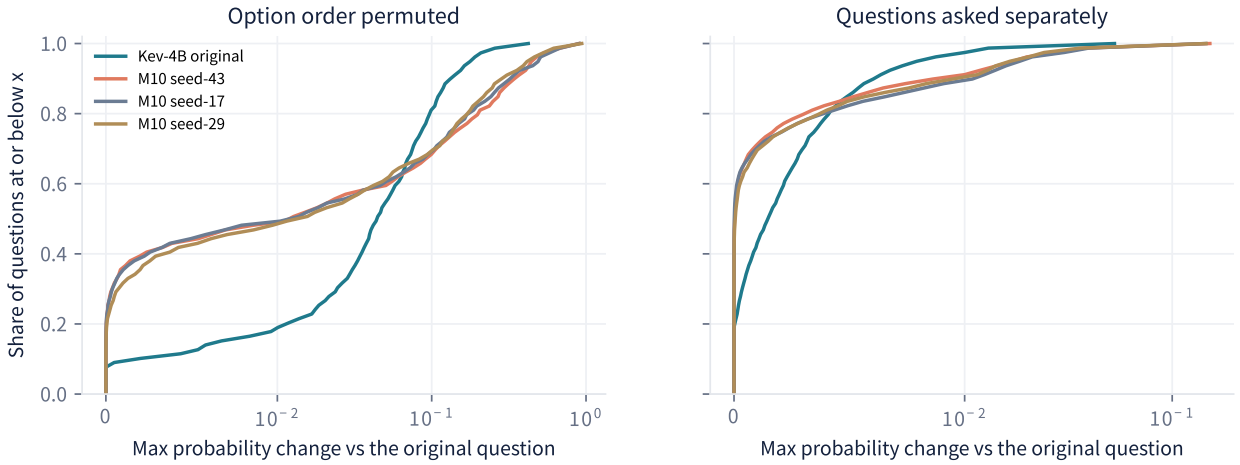


图 19　两类扰动的累积分布：横轴为同题最大概率变化，纵轴为不超过该变化的题目比例。

> 读法：曲线越靠左下越稳定。左图（选项顺序）微调版整体右移，右图（拆题）几乎重合。

外部对标：JevBench 与其它榜单

JevBench 是什么：一个第三方的"决策一致性"基准（Chen Feng，Queen's University Belfast；与 TypeSafe 无关），不考知识量，而是考模型的概率与选择是否满足 50 条一致性关系（例如同义改写后答案不变、互斥选项概率相加、选项顺序不改变相对概率）。它**没有金标**

答案，因此衡量的是 coherence，不是 accuracy。我们跑的是 mini 版本（1,240 次请求），这也是官方榜单的默认口径。

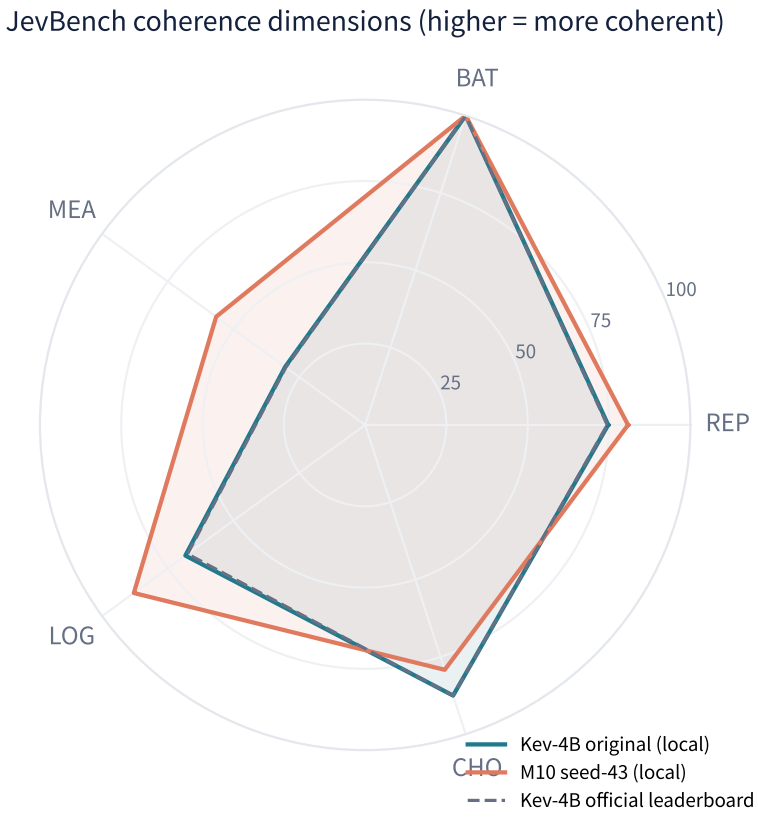


图 20　JevBench 五个维度的本地结果与官方 Kev-4B 公布值。

> 读法：越靠外越好。五个维度分别为 REP（表述不变性）、BAT（批次独立性）、MEA（概率测度）、LOG（逻辑顺序）、CHO（选项集合条件）。两条实线是我们的本地复跑；虚线是官方榜上的 Kev-4B 数值。

MODEL	OVERALL	95% CI	REP	BAT	MEA	LOG	CHO
Kev-4B original (local, bf16)	72.19	[70.2, 74.2]	74.7	100.0	30.4	68.3	87.5
M10 seed-43 (local, bf16)	80.91	[78.7, 83.2]	80.8	100.0	56.6	87.9	79.2
Kev-4B official leaderboard	**71.9**	**未公布**	**74.4**	**100.0**	**30.1**	**67.5**	**87.5**

官方榜读取于 2026-10-28（数据快照 2026-10-05）：官方 Kev-4B overall 71.92（95% CI [69.80, 73.88]，名次区间 9–15）、accuracy 87.87%（brier 0.164；240 题版本 71.20）。coherence 分数高不代表更准——榜单里的"均匀回答"参考模型 coherence 高达 89.4，但 accuracy 只有 39.8%。榜单也没有 TypeSafe Jev 托管 API 的条目；Kev 文档里引用的 Jev 分数（54.0）来自另一个 Decision Index，不能与这里的 coherence 混比。

> **本地与官方有差异吗？**本地原版 72.19（95% CI [70.2, 74.2]），官方榜 71.92（95% CI [69.8, 73.9]）；差值 +0.27 分，两独立区间正差检验 z = 0.19、p = 0.853。**差异不显著，在抽样误差范围内一致。**官方用 fp32 与 Python 3.11 环境，我们用 ROCm/bf16 服务，但两者的五维数值几乎逐项重合，说明本地复跑没有系统性偏低，也没有证据表明榜单被“刷分”。

> **微调后的位置：**seed-43 相对官方 Kev-4B 的 JevBench 差值为 +8.99 分（z = 5.80，p = 6.52e-09），在统计上明显更高；若放在已公布榜单里，大致位于前列。但这是 coherence 指标，且我们没有计算它的 accuracy（需要第三方金标），所以只能说“一致性更好”，不能据此宣称“更准”或“排名更高”。

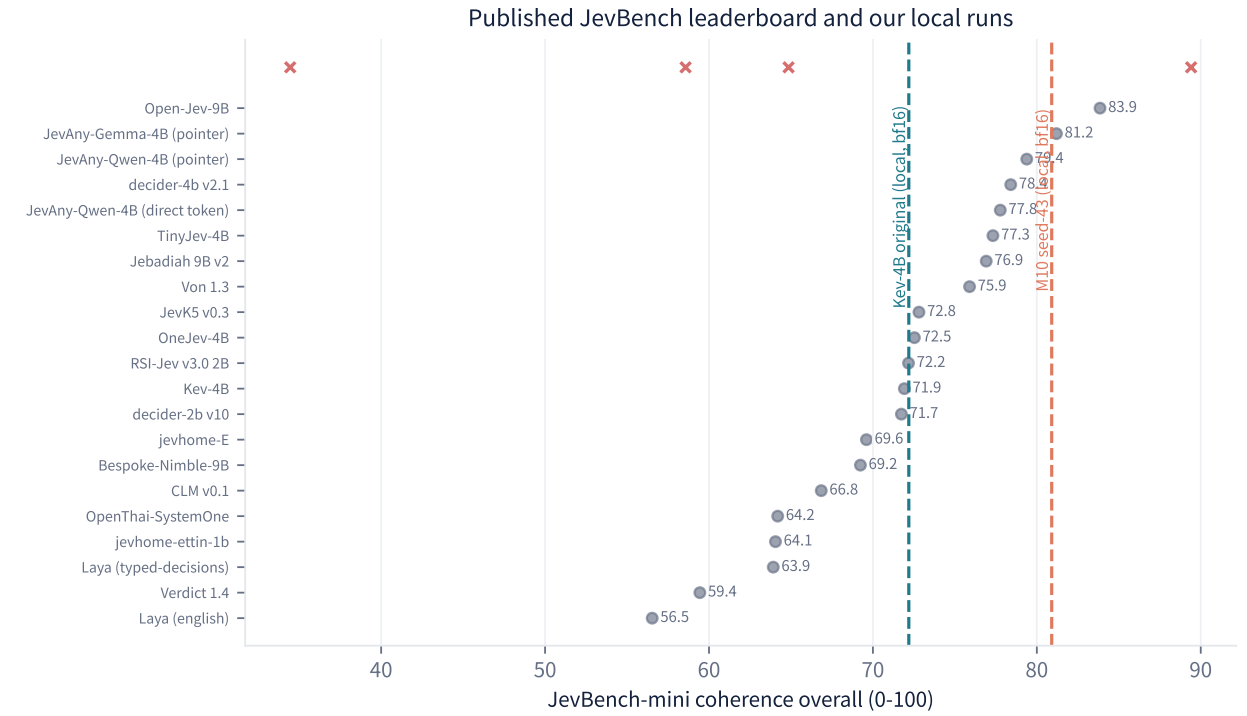


图 21　公开 JevBench 榜（点）与我们的两次本地复跑（虚线）。

> 读法：本地原版落点与官方 Kev-4B 几乎重合；seed-43 明显更高。注意榜单上还有“均匀回答”参考点，位置最高但不能当真——它只是说明该指标可以被刷。

官方 Jev API 的成绩在哪：JevBench 的公开榜单里没有 TypeSafe Jev 托管 API 的条目（榜上只有 21 个开源模型与 4 个 toy/random/uniform 参考）；能查到的官方 Jev 数字来自 Kev 作者的另一个对比表（Decision Index：Jev 54.0、Kev-4B 38.0、Kev-27B 52.3，accuracy 型指标），那是不同基准、不同指标，不能与本文的 coherence 分数并列。本文的官方对照只用 JevBench 榜单上的 Kev-4B 一行。

微调后的 seed-43 在 JevBench-mini 上为 **80.91**（95% CI [78.7, 83.2]），比本地原版高 8.7 分，提升主要来自 MEA（概率测度）与 LOG（逻辑一致性），CHO（选项集合）略降。这个

结果说明微调改变了模型的一致性行为，但不能替代准确率与校准结论：同一批权重在私有保留集上的准确率只高 0.95 个百分点，校准却明显变差。两项结果共同指向"能力结构改变"，而不是"整体变强"。

要不要提交榜单？ JevBench 没有公开提交表单，只接受作者邮箱与可复现脚本；我们的权重、固定的底座 revision 与 serve 脚本都已就绪，但本次未发邮件、未提交（零提交）。是否提交由 owner 决定；对外只写 locally reproduced, not listed。

我们调研过的榜单

做本次评测前，我们系统梳理了"Jev 类/决策模型类"的公开评测，结论是：真正的中立排行榜很少，多数是厂商发布表。主要条目如下（详细清单见仓库内 docs/reports/2026-10-27-jev-benchmarks.md）：

- **JevBench**（coherence，无金标，有公开榜；本文使用）
- **Kev suites / Decision Index**（Kev 官方发布的 accuracy/Brier/校准套件；部分分区不公开）
- **TypeSafe Jev / System One**（托管 API 基线，权重与数据不开源，无法本地复跑）
- **OpenJev、Laya typed-decisions、OpenDecider**（开源模型与自带 harness，多为厂商自评）
- **System One Bench**（第三方 accuracy/校准/延迟榜）——可作为后续补充方向

安全 / 伦理对齐方向的候选基准（本次未运行，仅列清单）

如果后续要把 PoL2 方向放到"知名度高、提交模型多"的安全榜上，我们调研到以下候选。"公开榜"指有公开可见的模型排名；"能否提交"以各自当前条款为准。本次未申请、未下载题目、未运行、未提交。适配度按接口形态（封闭选择题 vs 生成式红队）与关注点（误拦、伦理判断）评估。

基准	维护方 / 规模	公开榜 / 提交	对 POL2 的适配度
SafetyBench	清华 THU-CoAI（ACL 2024）；11,435 道中英四选一安全题，MIT	原在线评测入口已不可用；需从仓库自行运行，无正式公开榜	**高**：封闭四选一，与 PoL2 同构；建议作为第一补测
XSTest	过度拒答测试集；450 条，CC-BY-4.0	无榜单；本地二分类自评	**高**：直接对应"误拦率"，适合内部回归

基准	维护方 / 规模	公开榜 / 提交	对 POL2 的适配度
SALAD-Bench	安全基准；约 21k 题，6/16/66 三级分类，Apache-2.0	有 HF Space 公开榜；提交方式待核实，MCQ 子集可精确判分	中–高：有公开榜，但需筛出封闭选择子集
TrustLLM	多维可信度（真实性/安全/公平等）	可在线提交（学术运营）	中：维度多，需裁剪
ToxicChat	毒性对话真实样本	公开数据；无正式榜	中：需生成式适配
HELM Safety	Stanford CRFM；场景化安全评测	公开 leaderboard；运营方/申请制	低–中：生成式安全，需接口适配
AILuminate	MLCommons；AI 风险与可靠性基准 v1.0	公开榜；运营方/申请制	低–中：工业界参与多，指标偏生成式风险
AIR-Bench 2024	Alibaba；按监管/政策风险分类	有公开结果页；提交入口需核实	低–中：风险分类细，但非封闭选择

关键限制：接口能否直接匹配。PoL2 的输出是封闭选择（choice/score/noul），只有单选题与二分类基准能直接适配；HELM Safety、AIR-Bench、AILuminate、HarmBench、AgentHarm 都要求模型生成自然语言（或多步工具行动），直接上需要外接 verbalizer/agent，测到的将是“适配器 + 模型”，构念已经改变，因此它们只能作为间接探索，不能与 JevBench/保留集并列在一张表里。

建议：先本地补 **SafetyBench**（封闭选择题、与 PoL2 同构）与 **XSTest**（误拦率）；若要“公开榜可见度”再评估 **SALAD-Bench**（有公开榜、含可精确判分的 MCQ 子集）。HELM Safety / AILuminate / AIR-Bench 权威但偏生成式，需要先做接口适配。所有补测须另立预注册协议，不与本文的 JevBench/保留集数字混表。

运行成本、失败与经验

成本

评测在一张 AMD Radeon RX 7900 XT（20 GB，WSL2 + ROCm 7.2.1）上完成，单卡串行。四个权重各评测 9,052 条请求（含变体），每个约 16–17 分钟；每道题的中位延迟 83.8 ms（原版）到 77.7 ms（seed-43），p95 约 0.34–0.36 s。CPU（Ryzen 5700X，fp32）只用于公开样本的冒烟测试，不是性能基准。GPU 显存峰值未测（WSL 无相应监控模块）。

我们遵守了项目 GPU 纪律：只在允许时段启动单卡任务，运行前后检查系统事件日志（Kernel-Power/BugCheck/WHEA 无异常）。

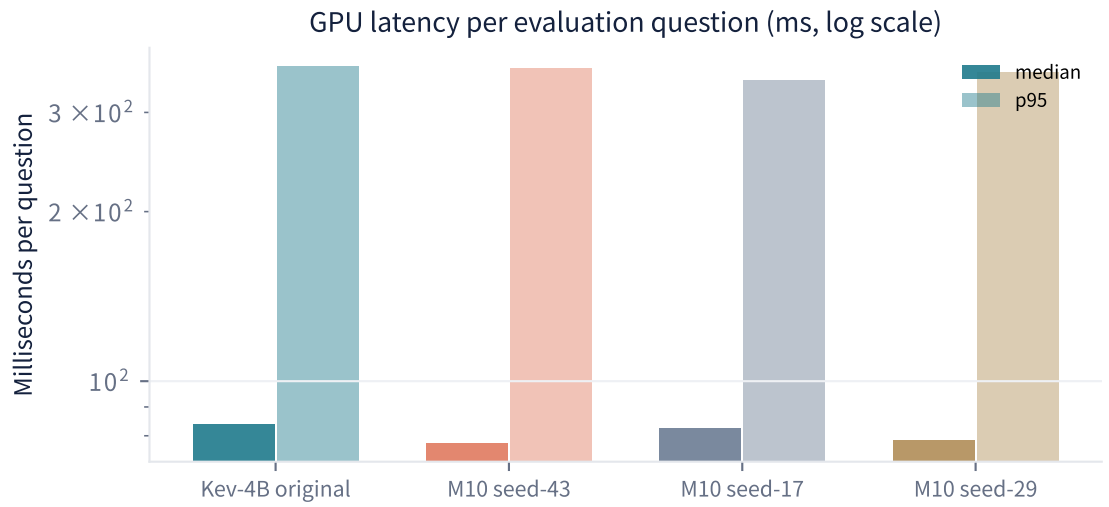


图 22　每道题的 GPU 延迟（对数纵轴；实心为 median，半透明为 p95）。

> 读法：四个权重延迟相差不大（中位约 78–84 ms，p95 约 0.34–0.36 s）。延迟不是本次结论的区分因素。

失败与修复（都发生在报告数字定稿之前）

1. **20 GB 显存装不下超长题目的 attention。**首轮完整评测在一条输入约 4.7k token 的题上触发 HIP OOM（eager attention 的 L×L 缓冲需要 4 GB）。处置：按硬件可执行性把 5 个条目（14 道题）单列为"本机不可评测"，其余题目重跑成功（0 拒绝）；这些条目没有进入任何数字。
2. **JevBench 的请求缓存会跨模型复用。**jevbench 0.1.0 的缓存键不包含被评测的 checkpoint，单独加 --no-cache 仍会返回上一模型的缓存响应，导致两个模型分数逐位相同。处置：每个模型使用全新缓存目录，并用服务端日志的 POST 计数（各 1,442 次）确认请求真的落到对应模型上，然后重跑。
3. **依赖版本超出上游声明。**Kev 声明 torch<2.9，本机是 2.9.1+rocm7.2.1。我们记录了完整环境并全流程实测通过；这项偏离已写入限制，不能把本报告数字与官方 fp32 结果直接等同。

可迁移的经验

- 报告"更准"之前先问"概率能不能信"：本次微调的准确率提升 0.95 个百分点，但 ECE 从 0.025 升到 0.21，实际部署含义完全相反。

- 配对比较比独立比较灵敏得多：同一道题上逐题比较能把“谁更好”的区间缩到 ±1 个百分点量级。
- 保留集只能评一次、不能用于任何选择；事后选出的 seed 必须明确标注，否则结论会被高估。
- 复现细节（固定 revision、固定缓存、记录环境与失败）比多跑一个模型更重要。

指标与统计词典 / 复现

指标定义

ACC（**准确率**）＝答对题数 / 总题数。

$\mathrm{Brier} = (1/N)\,\Sigma_i\,\Sigma_k\,(p_{ik} - y_{ik})^2$，其中 y 为 one-hot 金标；0 最好。

$\mathrm{NLL} = -(1/N)\,\Sigma_i \log p_{i,y_i}$，即正确答案概率的负对数均值；越低越好，对自信答错惩罚大。

$\mathrm{ECE} = \Sigma_{\mathrm{bins}}\,(n_b/N)\cdot|\mathrm{acc}_b - \mathrm{conf}_b|$；$\mathrm{coverage@5\%}$：按置信度降序接收、在接收集经验错误率 $\le 5\%$ 时能接收的最大比例；AURC 为风险-覆盖曲线下面积。

统计方法

配对 cluster bootstrap：以条目/情境簇为重抽样单位（同一条目的多道题一起抽），重抽样 2,000 次估计差值区间，处理同源题目的相关性。**McNemar 精确检验：**只用“一个对一个错”的题做二项检验，适合配对准确率。**置换检验：**在“两个模型可互换”的零假设下随机翻转每个簇的差值符号，得到 p 值。**Holm 校正：**对三个 seed 的多重比较控制族错误率。**Wilson 区间：**单模型比例的 95% 区间，适合小比例与中等样本。

本文做过的与没做的事

- 做过：固定数据与权重 revision；对私有保留集只导出聚合；配对统计、校准与风险分析；JevBench 本地复跑；与官方榜的误差范围内对照。
- 没做：多 seed 重新训练；在保留集上拟合温度或调阈值；语义层面的训练数据去重；JevBench 的 accuracy（需第三方金标）；榜单提交。

- 可复现材料：仓库 benchmark/kev_prefix/（评测代码与单测）、结果目录的聚合 JSON 与版本清单；原始逐题记录按数据边界在评测后删除，不进入仓库。